

Sujet d'Examen :

Diagnostic assisté et tri d'urgence multimodal en télémédecine

L'engorgement des services d'urgence et le développement de la télémédecine imposent des solutions de tri rapide et fiables. Ce projet consiste à **concevoir un système d'intelligence artificielle capable de classer le degré d'urgence d'une situation à partir de données hybrides** (numériques et textuelles).

Pour créer ce système d'IA, vous aurez à votre disposition un jeu de données composé de données collectées au sein d'un établissement médical. Il contient 2000 échantillons pour lesquelles nous connaissons le niveau d'urgence (c'est la décision prise par le professionnel de santé à la lecture des informations).

Dans le détail, chaque échantillon est composé de :

- **Données tabulaires** : Âge, données administratives, constantes vitales (fréquence cardiaque, tension, température, saturation), antécédents médicaux (pathologie chronique) et durée des symptômes.
- **Données textuelles** : Description libre rédigée par le patient ou rapport d'appel du régulateur détaillant la plainte principale.
- **Variable cible** : Niveau d'urgence (0 : non urgent, 1 : urgence relative, 2 : urgence vitale).

L'enjeu pour vous de réussir à exploiter ces données pour prédire si une situation rencontrée relève de l'urgence vitale, d'une urgence relative, ou au contraire ne contient aucun caractère urgent. Vous devrez pour ceci respecter les contraintes réglementaires et éthiques liées à l'usage de données personnelles sensibles. Vous devrez aussi adapter vos apprentissages afin de limiter le nombre de mauvaises classifications dangereuses d'un point de vue métier.

Objectif du projet

L'objectif est de **prédire le degré d'urgence d'une demande entrante**, à partir des informations renseignées. Cette tâche est donc une tâche supervisée de classification à 3 classes.

Vous devrez :

- Entraîner plusieurs modèles (Random Forest, XGBoost, Réseaux de neurones, etc....) et comparer leurs performances.
- Utiliser des métriques de classification appropriées : **Accuracy**, **F1-score pondéré** et **Matrice de confusion**.
- Mettre en place une **validation croisée** pour garantir la robustesse des résultats.
- Discuter de l'architecture de modèle qui présente le meilleur rapport performance / coût computationnel d'inférence

Une fois cette tâche effectuée, vous devrez entamer une réflexion sur un **enjeu éthique majeur de votre use-case** : « *une situation d'un niveau d'urgence 2 (urgence vitale) classé niveau 1, ou encore pire, 0, est une erreur bien plus grave qu'une situation d'un niveau d'urgence 0 classé niveau 1 ou 2.* »

Concrètement, il vous sera demandé de **modifier votre meilleur modèle pour favoriser la diminution des erreurs critiques**. Pour cela, vous devrez trouver quelle métrique favoriser lors de l'apprentissage.

Analyse comparée des scénarios

Un point essentiel de votre mission sera de **comparer les performances obtenues selon différents scénarios d'entraînement**, afin d'estimer l'impact des données sensibles ou des différents types de données disponibles :

- **Scénario 1 – Approche multimodale complète** : Utilisation de l'intégralité des variables (tabulaires + texte vectorisé).
- **Scénario 2 – Sans variables sensibles** : Retrait des variables éthiquement discutables ou sources de biais avec justification argumentée.
- **Scénario 3 – Diagnostic "aveugle" (NLP seul)** : Prédiction basée exclusivement sur le récit textuel des symptômes pour tester la robustesse du modèle de langage.
- **Scénario 4 – Données cliniques pures (Tabulaire seul)** : Prédiction basée uniquement sur les constantes vitales et l'âge, sans l'apport du contexte sémantique.

Votre objectif est de **documenter et commenter l'impact de chaque scénario sur les performances des modèles**, et d'**argumenter sur le choix du modèle et des données** à utiliser dans un contexte réel, en tenant compte des enjeux **éthiques, légaux et de robustesse**.

Industrialisation et Déploiement

Une fois les modèles de prédiction sélectionnés et validés, vous passerez à la phase d'**industrialisation de la solution IA**, en concevant

une application complète accessible à un utilisateur non technique. Cette application sera composée de deux éléments principaux : une **API de prédiction** et une **interface utilisateur graphique**.

L'**API** permettra de mettre à disposition le modèle d'IA sous forme de service, que l'on pourra interroger via des requêtes HTTP POST. Elle devra inclure un mécanisme de chargement du modèle entraîné, et exposer au minimum une route pour prédire le niveau d'urgence d'une situation à partir des caractéristiques fournies, une route de réentraînement monitoré et une route pour mesurer la santé de votre API. Vous veillerez à **journaliser chaque requête**, en sauvegardant les entrées, les sorties, les dates d'inférence, et idéalement l'utilisateur (ou ID de session). Une attention particulière sera portée à la **gestion des erreurs**, à la **validation des données entrantes**, et à la **robustesse de l'API**.

L'**interface graphique** devra permettre à un utilisateur de renseigner les informations liées à une situation potentiellement urgente via un formulaire simple, d'obtenir une prédiction claire et interprétable, et de consulter un historique des inférences si possible.

Par ailleurs, vous intégrerez des outils de **suivi de modèle** avec MLflow pour tracer les versions du modèle, ses hyperparamètres, ses performances, et permettre un **versionning contrôlé**. Enfin, un **monitoring de l'API** (temps de réponse, erreurs, uptime kuma) pourra être mis en place à l'aide de solutions comme Prometheus + Grafana ou simplement via des logs et alertes automatisées.

Le projet devra intégrer une démarche **CI/CD** complète, en utilisant **GitHub Actions** pour automatiser les étapes clés du cycle de vie du code : tests, linting, entraînement du modèle et déploiement. À chaque mise à jour de la branche principale, une image **Docker** de l'API sera construite automatiquement et déployée sur l'infrastructure cible, garantissant un déploiement reproductible, traçable et conforme aux bonnes pratiques d'ingénierie IA.

Cette phase vise à valider votre capacité à **transformer un modèle de data science en une solution exploitable en environnement réel**, dans le respect des contraintes de fiabilité, d'éthique et de gouvernance des données.

Éthique et Cadre Réglementaire

Une section du projet devra traiter spécifiquement de la conformité au **RGPD** (données de santé sensibles) et de la responsabilité juridique en cas d'erreur de classification de l'urgence vitale.

Description des données disponibles

Colonne	Description
patient_id	Identifiant unique du patient.
sexe	Sexe du patient : F (Femme) ou H (Homme).
age	Âge du patient (en années).
zone_vie	Type de résidence : U (Urbain) ou R (Rural).
source	Origine de la donnée : appel (Transcription d'appel) ou chat (Interface texte).
freq_cardiaque	Fréquence cardiaque en battements par minute (bpm).
tension_sys	Tension artérielle systolique (mmHg).
temp	Température corporelle en degrés Celsius (°C).
sat_oxygene	Taux de saturation en oxygène (en %).
antecedents	Présence de pathologies chroniques : 1 (Oui), 0 (Non).
duree_symptomes	Temps écoulé depuis l'apparition des symptômes (en heures).
description_symptomes	Texte libre décrivant les douleurs, sensations ou l'état général.
niveau_urgence	Variable cible : 0 (Non urgent), 1 (Urgence relative), 2 (Urgence vitale).